

DISTRIBUIÇÕES CONJUNTAS DE PROBABILIDADE

Capítulo 5

DISTRIBUIÇÕES CONJUNTAS DE PROBABILIDADE

- ♦ No estudo de experiências aleatórias é muitas vezes necessário caracterizar diferentes variáveis aleatórias a partir de um espaço amostral.
- ♦ Nestas circunstâncias é muitas vezes importante pôr em evidência **não só as propriedades individuais das variáveis** mas também **as propriedades que dizem respeito à forma como as variáveis se encontram associadas**.
 - » Isto envolve a definição de **distribuições conjuntas de probabilidade**

DISTRIBUIÇÕES CONJUNTAS DE PROBABILIDADE

- ♦ **Distribuições conjuntas de probabilidade** estudam as propriedades conjuntas de mais do que uma variável aleatória

		Marital status				$P(S_i)$
		Single M_1	Married M_2	Widowed M_3	Divorced M_4	
Sex	Male S_1	0.129	0.298	0.013	0.040	0.480
	Female S_2	0.104	0.305	0.057	0.054	0.520
	$P(M_j)$	0.233	0.603	0.070	0.095	1.000


3

DISTRIBUIÇÕES CONJUNTAS DE PROBABILIDADE

- ♦ **Exemplo:** Considere-se novamente um casal com três filhos, definindo as seguintes variáveis aleatórias:

- **X: número de raparigas**
- **Y: número de seqüências de filhos com o mesmo sexo**

- ♦ Considere-se que pretendemos determinar a probabilidade da família ter uma rapariga (**X=1**) e duas seqüências de filhos com o mesmo sexo (**Y=2**).



4

FUNÇÃO CONJUNTA DE PROBABILIDADE

♦ Função conjunta de probabilidade das variáveis X e Y

Representa-se por $P(x,y)$ ou $P(X=x, Y=y)$

- X: número de raparigas
- Y: número de sequências de filhos com o mesmo sexo

	Resultados possíveis	Probabilidade	Valor X	Valor Y
	rz,rz,rz	0.14	0	1
X=1	rz,rz,rg	0.13	1	2
	rz,rg,rz	0.13	1	3
	rz,rg,rg	0.12	2	2
Y=2	rg,rz,rz	0.13	1	2
	rg,rz,rg	0.12	2	3
	rg,rg,rz	0.12	2	2
	rg,rg,rg	0.11	3	1

$$P(X=1 \text{ e } Y=2) = 0.13 + 0.13 = 0.26$$

Representação tabular da função conjunta de probabilidade

		Y		
P(x,y)		1	2	3
X	0	0.14	0	0
	1	0	0.26	0.13
	2	0	0.24	0.12
	3	0.11	0	0

$$\sum_x \sum_y P(x,y) = 1$$

5

FUNÇÃO MARGINAL DE PROBABILIDADE

- ♦ Considere-se que estamos apenas interessados na variável aleatória X, mas apenas conhecemos a função conjunta de probabilidade $P(x,y)$
- ♦ Quando a função de probabilidade de uma variável é obtida a partir da função conjunta designa-se por **função marginal de probabilidade**

		Y			
		P(x,y)	1	2	3
X	0	0.14	0	0	
	1	0	0.26	0.13	
	2	0	0.24	0.12	
	3	0.11	0	0	
P(y)		0.25	0.5	0.25	

P(x)
0.14
0.39
0.36
0.11

Função marginal de probabilidade da variável X

$$P(x) = \sum_y P(x, y)$$

Função marginal de probabilidade da variável X

$$P(x) = \sum_y P(x,y)$$

6

FUNÇÃO CONDICIONAL DE PROBABILIDADE

- ◆ Considere-se a **função de probabilidade conjunta**, $P(x,y)$, e as **funções de probabilidade marginal de X**, $P(x)$, e de Y, $P(y)$.

» Calcule-se agora a probabilidade da família **ter uma rapariga (X=1)**, **dado que** tem 2 seqüências de filhos com o mesmo sexo (Y=2)

		Y				
		P(x,y)	1	2	3	P(x)
X	0	0.14	0	0		0.14
	1	0	0.26	0.13		0.39
	2	0	0.24	0.12		0.36
	3	0.11	0	0		0.11
		P(y)	0.25	0.5	0.25	

$$P(X=1 | Y=2) = \frac{P(X=1 \text{ e } Y=2)}{P(Y=2)}$$

$$= \frac{0.26}{0.50} = 0.52$$

- ◆ A função $P(x|y)$ designa-se por **função condicional de probabilidade** de x dado y. É definida pela seguinte expressão:

$$P(x | y) = \frac{P(x, y)}{P(y)}$$

7

INDEPENDÊNCIA ENTRE VARIÁVEIS

- ◆ Duas variáveis aleatórias X e Y dizem-se independentes se para todos os valores x e y, os acontecimentos $X=x$ e $Y=y$ forem independentes.

» Isto implica que para **quaisquer valores x e y** :

$$\forall x, y : \begin{cases} \text{Probabilidade } (X=x | Y=y) = \text{Probabilidade } (X=x) \\ \text{Probabilidade } (Y=y | X=x) = \text{Probabilidade } (Y=y) \end{cases}$$

- » Daqui resulta a seguinte **condição necessária e suficiente** de independência entre duas variáveis aleatórias:

$$P(x, y) = P(x) \cdot P(y)$$

Demonstração:

$$P(x | y) = \frac{P(x, y)}{P(y)} = P(x)$$

$$\Rightarrow P(x, y) = P(x) \cdot P(y)$$

8

INDEPENDÊNCIA ENTRE VARIÁVEIS

- ♦ **Exemplo:** Será que as variáveis **X (nº de raparigas)** e **Y (nº de sequências de filhos com o mesmo sexo)** definidas anteriormente são independentes?

» Para as variáveis serem independentes a expressão $P(x, y) = P(x) \cdot P(y)$ terá de se verificar **para quaisquer valores** de X e de Y.

Considerando por exemplo **X=0 e Y=1**

$$P(X = 0 \text{ e } Y = 1) \stackrel{?}{=} P(X = 0) \cdot P(Y = 1)$$

$$0.14 \neq 0.14 \times 0.52$$

Logo, **as variáveis não são independentes**

		Y			P(x)
		1	2	3	
X	0	0.14	0	0	0.14
	1	0	0.26	0.13	0.39
	2	0	0.24	0.12	0.36
	3	0.11	0	0	0.11
P(y)		0.25	0.5	0.25	


9

COVARIÂNCIA E CORRELAÇÃO

- ♦ A **covariância** e a **correlação** são medidas **do grau de relacionamento linear** entre duas variáveis.

» Os seus conceitos serão introduzidos através do seguinte exemplo:

		X				
		10	20	30	40	50
Y	6					0.10
	5		0.10		0.20	
	4			0.20		
	3			0.20		0.10
	2	0.10				
	1					



» O diagrama põe em evidência a relação existente entre as variáveis X e Y: **Y tende a crescer com X e vice-versa.**


13

COVARIÂNCIA E CORRELAÇÃO

- Considerem-se os desvios entre qualquer ponto (x,y) e o ponto central (μ_X, μ_Y) $\rightarrow (x - \mu_X, y - \mu_Y)$

$$\mu_X = \sum_x x \cdot P(x) = 30$$

$$\mu_Y = \sum_y y \cdot P(y) = 4$$



- Os pontos situados nos quadrantes **NE** e **SW** têm desvios com o mesmo sinal, pelo que o produto $(x - \mu_X) \cdot (y - \mu_Y)$ é sempre **positivo**.
- Para os pontos nos quadrantes **NW** e **SE** este produto é sempre **negativo**.

14

COVARIÂNCIA E CORRELAÇÃO

- Pode obter-se uma medida adequada do grau de **relacionamento linear** entre duas variáveis calculando a soma pesada destes produtos, na qual os pesos são as probabilidades conjuntas $P(x,y)$.

- Esta medida é a **COVARIÂNCIA**:

$$\gamma_{xy} = \text{Cov}(X, Y) = \sum_x \sum_y (x - \mu_X) \cdot (y - \mu_Y) \cdot P(x, y)$$

$$\gamma_{xy} > 0$$

se **as variáveis crescem (ou decrescem) juntas** (i.e., as probabilidades conjuntas concentram-se nos quadrantes **NE** e **SW**);

$$\gamma_{xy} < 0$$

se quando **uma variável cresce** a outra **decresce**;

$$\gamma_{xy} \cong 0$$

se as probabilidades conjuntas **se distribuírem igualmente** pelos quatro quadrantes, indicando a inexistência de qualquer relação linear entre as variáveis.

15

COVARIÂNCIA E CORRELAÇÃO

- ♦ No exemplo anterior:

		X				
		P(x,y)	10	20	30	40
Y	6					0.10
	5			0.10		0.20
	4				0.20	
	3			0.20		0.10
	2		0.10			
	1					

$$\mu_X = \sum_x x \cdot P(x) = 30$$

$$\mu_Y = \sum_y y \cdot P(y) = 4$$

$$\gamma_{xy} = \text{Cov}(X, Y) = \sum_x \sum_y (x - \mu_X) \cdot (y - \mu_Y) \cdot P(x, y)$$

$$\begin{aligned} \gamma_{xy} &= (10 - 30) \cdot (2 - 4) \cdot 0.10 + (20 - 30) \cdot (3 - 4) \cdot 0.20 + (20 - 30) \cdot (5 - 4) \cdot 0.10 + \\ &\quad + (30 - 30) \cdot (4 - 4) \cdot 0.20 + (40 - 30) \cdot (3 - 4) \cdot 0.10 + (40 - 30) \cdot (5 - 4) \cdot 0.20 + \\ &\quad + (50 - 30) \cdot (6 - 4) \cdot 0.10 = \\ &= 4 + 2 + (-1) + 0 + (-1) + 2 + 4 = \\ &= 10 \end{aligned}$$

16

COVARIÂNCIA E CORRELAÇÃO

- ♦ A covariância tem o **inconveniente de ser afectada pelas unidades** em que as variáveis são medidas. Para evitar esta limitação, reescala-se a covariância definindo a medida de **CORRELAÇÃO**:

$$\rho_{xy} = \frac{\gamma_{xy}}{\sigma_X \cdot \sigma_Y} \quad -1 \leq \rho_{xy} \leq 1$$

$$\rho_{xy} > 0$$

indica **uma relação linear entre as variáveis** consideradas, de tal forma que **quando X aumenta, Y também aumenta**. Se $\rho_{xy} = 1$ indica que o grau de relacionamento linear é **perfeito**, de tal forma que $Y = \alpha + \beta \cdot X$, com $\beta > 0$;

$$\rho_{xy} < 0$$

indica **uma relação linear entre as variáveis consideradas**, de tal forma que **quando uma aumenta a outra diminui**. Se $\rho_{xy} = -1$ indica que o grau de relacionamento linear é **perfeito**, de tal forma que $Y = \alpha + \beta \cdot X$, com $\beta < 0$;

$$\rho_{xy} \cong 0$$

indica que o **grau de relacionamento linear** entre as variáveis é **nulo**.

17

COVARIÂNCIA E CORRELAÇÃO

- ♦ No exemplo anterior:

		X					P(x)
		10	20	30	40	50	
Y	P(x,y)					0.10	0.10
	6						0.10
	5		0.10		0.20		0.30
	4			0.20			0.20
	3		0.20		0.10		0.30
	2	0.10					0.10
	1						0
P(x)		0.10	0.30	0.20	0.30	0.10	

$$\rho_{xy} = \frac{\gamma_{xy}}{\sigma_x \cdot \sigma_y} = \frac{10}{11.83 \times 1.18} = 0.77$$


$$\begin{aligned}\sigma_x &= \sqrt{\sum_x (x - \mu_x)^2 \cdot p(x)} = \\ &= \sqrt{(10-30)^2 \cdot 0.10 + (20-30)^2 \cdot 0.30 + (30-30)^2 \cdot 0.20 + (40-30)^2 \cdot 0.30 + (50-30)^2 \cdot 0.10} \\ &= \sqrt{40 + 30 + 0 + 30 + 40} = 11.83 \\ \sigma_y &= \sqrt{\sum_y (y - \mu_y)^2 \cdot p(y)} = \\ &= \sqrt{(6-4)^2 \cdot 0.10 + (5-4)^2 \cdot 0.30 + (4-4)^2 \cdot 0.20 + (3-4)^2 \cdot 0.30 + (2-4)^2 \cdot 0.10} \\ &= \sqrt{0.4 + 0.3 + 0 + 0.3 + 0.4} = 1.18\end{aligned}$$

18

COVARIÂNCIA E CORRELAÇÃO

- ♦ Variáveis independentes $\Rightarrow$ não existe qualquer relação entre elas $\Rightarrow$ o grau de relacionamento linear entre elas é nulo $\Rightarrow \rho_{xy} = 0$
- ♦ No entanto, **se o coeficiente de correlação for nulo não se pode daí depreender que as variáveis sejam independentes** (uma vez que podem existir relações não-lineares entre elas).

» Exemplo: $N = |M|$



$$\mu_M = 0$$

$$\mu_N = 2$$

$$\gamma_{MN} = \rho_{MN} = 0$$

Apesar da covariância e da correlação entre as variáveis ser nula, **as variáveis M e N não são independentes**: O valor de N depende do valor de M (é de facto igual ao valor absoluto de M). 19

CARACTERIZAÇÃO DE AMOSTRAS BIVARIADAS

Estatística
Descritiva

Medidas **do grau de ajustamento da relação linear** aos dados:

PRODUTO CRUZADO MÉDIO $\frac{1}{N} \cdot \sum_{n=1}^N (x_n - \bar{x}) \cdot (y_n - \bar{y})$

(Quanto mais próximo de “0” em valor absoluto, mais fraca será a relação linear entre os valores de x_n e y_n)

COVARIÂNCIA AMOSTRAL (permite **inferir acerca da população**)

$$c_{XY} = \frac{1}{N-1} \cdot \sum_{n=1}^N (x_n - \bar{x}) \cdot (y_n - \bar{y})$$

COEFICIENTE DE CORRELAÇÃO AMOSTRAL (**medida adimensional**)

$$r_{XY} = \frac{\frac{1}{N-1} \cdot \sum_{n=1}^N (x_n - \bar{x}) \cdot (y_n - \bar{y})}{\sqrt{\frac{1}{N-1} \cdot \sum_{n=1}^N (x_n - \bar{x})^2} \cdot \sqrt{\frac{1}{N-1} \cdot \sum_{n=1}^N (y_n - \bar{y})^2}} = \frac{c_{XY}}{s_X \cdot s_Y} \quad (-1 \leq r_{XY} \leq 1)$$

CARACTERIZAÇÃO DE AMOSTRAS BIVARIADAS

Estatística
Descritiva

Medidas **do grau de ajustamento da relação linear** aos dados:

COEFICIENTE DE DETERMINAÇÃO (**medida adimensional**)

r^2_{XY} , designado por **COEFICIENTE DE DETERMINAÇÃO**, representa a proporção da variação dos dados y_n que é explicada pela relação linear, a partir da variação dos dados x_n .

Dito de outra forma, quando duas variáveis estão associadas, a variação de uma delas implica algum tipo de variação na outra. Uma medida de variabilidade é a variância.

Dizer que o coeficiente de determinação é, por exemplo de 0.6, significa que 60% da variância de uma das variáveis é provocada (explicada) pela outra variável e apenas 40% de natureza independente.

COVARIÂNCIA E CORRELAÇÃO

- » **Efeito de Regressão para a Média:**
quando duas variáveis estatísticas têm **uma correlação imperfeita devido à existência de ruído**, os valores extremos de uma das variáveis tendem a ser acompanhados por valores menos extremos da outra;
- » **A falácia da regressão** é o erro lógico caracterizado por ignorarmos **as inevitáveis flutuações de variáveis imperfeitamente correlacionadas**, atribuindo-lhes **relações causais inexistentes**;
- » Esta falácia é conhecida por **“post hoc, propter hoc” (“depois de, logo provocado por”)**, ou seja, assumir que **correlação implica causalidade**.

Jorge Buescu “O Mistério do Bilhete de Identidade e Outras Histórias”, Gradiva 24

COVARIÂNCIA E CORRELAÇÃO

» Exemplo:

Califórnia, segunda metade do séc. XIX: no espaço de uma geração tanto **o número de padres** como **o consumo de álcool quadruplicaram**. Qual a explicação?

As duas variáveis estão fortemente correlacionadas sem existir nenhuma relação causal entre si. Ambas são uma medida indirecta de outra variável que, essa sim, determina as relações causais: a população da Califórnia (**o Tertium Quid – o problema da 3ª variável**)

Jorge Buescu “O Mistério do Bilhete de Identidade e Outras Histórias”, Gradiva

25


7 Deadly Statistical Sins Even the Experts Make

3: Assuming Correlation = Causation

When you see correlation—a linear association between two variables—it's tempting to conclude that a change in one causes a

change in the other. But correlation doesn't mean a cause-and-effect relationship exists.

Let's say we analyze data that shows a strong correlation between ice cream sales and murder rates. When ice cream sales are low in winter, the murder rate is low. When ice cream sales are high in summer, the murder rate is high. That doesn't mean ice cream sales cause murder. Given the fact that both ice cream sales and the murder rate are highest in the summer, the data suggest rather that both are affected by another factor: the weather.



26

COMBINAÇÃO LINEAR DE VARIÁVEIS

- ◆ Considere-se o caso da variável **W** ser obtida combinando linearmente as variáveis **X** e **Y**:

$$W = a + b \cdot X + c \cdot Y$$

» **Exemplo:** Considere-se as variáveis que representam o peso e a altura de uma conjunto de indivíduos, com a seguinte distribuição conjunta de probabilidade [variável altura (A) ; Variável peso (B)]:

- Defina a função de probabilidade da variável **R = B - 40*A** obtida a partir das variáveis peso (B) e altura (A) definidas.

Função conjunta de probabilidade P(a,b)

		B: Peso (kg)					
		P(a,b)	75	76	77	79	81
A: Altura (m)	1.73	1/7					
	1.76	2/7					
	1.78		1/7	1/7	1/7		
	1.82						1/7

Função de probabilidade da variável transformada

R	P(r)
5.8 = 75-40*1.73	1/7
4.6 = 75-40*1.76	2/7
4.8 = 76-40*1.78	1/7
5.8 = 77-40*1.78	1/7
7.8 = 79-40*1.78	1/7
8.2 = 81-40*1.82	1/7

27

COMBINAÇÃO LINEAR DE VARIÁVEIS: valor esperado e variância

- ♦ Os parâmetros da distribuição de probabilidade da variável transformada, que resulta da combinação entre variáveis aleatórias, podem ser calculados de duas formas equivalentes:
 - » directamente a partir da distribuição da variável transformada, ou
 - » com base nas distribuições das variáveis originais e na função que define a combinação linear dessas variáveis: $W = a + b \cdot X + c \cdot Y$

Valor esperado de W:

$$E(W) = a + b \cdot E(X) + c \cdot E(Y)$$

Variância de W:

$$\text{Var}(W) = b^2 \cdot \text{Var}(X) + c^2 \cdot \text{Var}(Y) + 2 \cdot b \cdot c \cdot \text{Cov}(X, Y)$$

28

COMBINAÇÃO LINEAR DE VARIÁVEIS: valor esperado e variância

- ♦ No exemplo anterior:

		X				
		10	20	30	40	50
Y	6					0.10
	5		0.10		0.20	
	4			0.20		
	3			0.20	0.10	
	2	0.10				
	1					
P(x)		0.10	0.30	0.20	0.30	0.10

$$\mu_X = \sum_x x \cdot P(x) = 30$$

$$\mu_Y = \sum_y y \cdot P(y) = 4$$

$$\sigma_X = 11.83$$

$$\sigma_Y = 1.18$$

$$\text{Cov}(X, Y) = 10$$

Calcule o valor esperado e a variância da variável $W = 3 \cdot X - 5 \cdot Y + 6$

$$E(W) = 3 \cdot E(X) - 5 \cdot E(Y) + 6 = 3 \times 30 - 5 \times 4 + 6 = 76$$

$$\begin{aligned} \text{Var}(W) &= 3^2 \times \text{Var}(X) + (-5)^2 \times \text{Var}(Y) + 2 \times 3 \times (-5) \times \text{Cov}(X, Y) \\ &= 3^2 \times (11.83)^2 + (-5)^2 \times (1.18)^2 + 2 \times 3 \times (-5) \times 10 = \\ &= 994.35 \end{aligned}$$

29

COMBINAÇÃO LINEAR DE VARIÁVEIS: valor esperado e variância

- ♦ A soma de duas variáveis é um caso particular de combinação linear das duas variáveis.

» Seja $S = Y_1 + Y_2$. As expressões anteriores convertem-se em:

Valor esperado de S:

$$E(S) = E(Y_1 + Y_2) = E(Y_1) + E(Y_2)$$

Variância de S:

$$\text{Var}(S) = \text{Var}(Y_1 + Y_2) = \text{Var}(Y_1) + 2 \cdot \text{Cov}(Y_1, Y_2) + \text{Var}(Y_2)$$

30

COMBINAÇÃO LINEAR DE VARIÁVEIS: valor esperado e variância

- ♦ As expressões anteriores são generalizáveis para qualquer número de variáveis:

» O **valor esperado da soma de N variáveis** $Y_1, Y_2, \dots, Y_N$, é igual à soma dos valores esperados destas variáveis:

$$E(Y_1 + Y_2 + \dots + Y_N) = E(Y_1) + E(Y_2) + \dots + E(Y_N)$$

» Quanto à expressão da **variância da soma de N variáveis**:


$$\text{Var}(Y_1 + Y_2 + \dots + Y_N) = \text{Var}(Y_1) + \dots + \text{Var}(Y_N) + 2 \cdot \sum_{i=1}^{N-1} \sum_{j=i+1}^N \text{Cov}(Y_i, Y_j)$$

31

COMBINAÇÃO LINEAR DE VARIÁVEIS: valor esperado e variância

EXEMPLO

Admita que um determinado compressor de frigorífico utiliza um componente constituído por um cilindro e pistão com a configuração que se apresenta na figura. A folga ente o cilindro e o pistão é $F = D - d$. O desvio padrão de D é $0,01\text{mm}$ e o de d é $0,007\text{mm}$.



Considere duas hipóteses para o cálculo da **variabilidade da folga**:

1ª hipótese: D e d são independentes

$$\sigma_F^2 = \text{Var}(D - d) = \sigma_D^2 + \sigma_d^2 = 0,01^2 + 0,007^2 = 1,49 \times 10^{-4}$$

$$\sigma_F = \mathbf{0,01221}$$

2ª hipótese: D e d não são independentes (com $\rho_{Dd} = 0,9$)

$$\gamma_{Dd} = \rho_{Dd} \cdot \sigma_D \cdot \sigma_d = 0,9 \cdot 0,01 \cdot 0,007 = 6,3 \cdot 10^{-5}$$

$$\sigma_F^2 = \sigma_D^2 + \sigma_d^2 - 2 \cdot \gamma_{Dd} = 0,01^2 + 0,007^2 - 2 \cdot 6,3 \times 10^{-5}$$

$$\sigma_F = \mathbf{0,00479}$$

No caso das montagens e acoplamentos pode tirar-se partido da correlação!

32

Problema Extra



1. Numa fábrica de máquinas-ferramenta localizada nos arredores do Porto, foi constituído um lote de cinco prensas para enviar para os Estados Unidos da América. Momentos antes de a encomenda ser despachada, descobriu-se que, de entre aquelas cinco prensas, existiam três que estavam equipadas com motores eléctricos não apropriados para funcionar nos EUA.
Nestas condições, as prensas vão ser testadas sucessivamente até que sejam identificadas todas as que contêm tais motores. Denote-se por N_1 o número de testes efectuados até ser identificada a primeira prensa defeituosa e por N_2 o número adicional de testes até ser identificada a segunda prensa defeituosa.

(a) Verifique se N_1 e N_2 são independentes. (3 VALORES)

(b) Calcule a covariância entre N_1 e N_2 e interprete o resultado que obtiver (2 VALORES)

34