

- Em todas as suas respostas defina e apresente, com clareza, a **terminologia** (acontecimentos e variáveis aleatórias), a **metodologia** e as **hipóteses subjacentes aos diferentes passos da sua análise**.
- Deve também mostrar explicitamente o raciocínio, apresentando as fórmulas que usar e mostrando como se utilizam no caso concreto substituindo os valores (nas fórmulas com somatórios basta mostrar a primeira e a última parcela). Não é necessário mostrar cálculos detalhados.
- Nos **testes de hipóteses** que realizar deve apresentar também o **valor de prova**, mesmo que aproximado, e uma **conclusão no contexto do enunciado**.
- Os problemas 1 e 2 são de resposta obrigatória, pode optar por responder ao problema 3 ou ao problema 4.
- Deve responder a cada problema em folhas diferentes.

1. (8 VALORES) Na FEUP sabe-se que os 200 alunos inscritos na cadeira de MESTAT realizam regularmente fichas de avaliação, com duração de 30 minutos, no *Moodle*. A realização de uma ficha implica que o aluno tenha que fazer *upload* de ficheiros com a sua resolução (ex: documento *Word*, imagem, PDF). Por sua vez, o servidor da Universidade do Porto destinado à plataforma *Moodle*, tem disponível uma capacidade de 40MB para *upload* de todos os ficheiros de uma ficha de avaliação.

De forma a evitar a sobrecarga do servidor, durante o 2.º semestre, os professores de MESTAT incentivaram os alunos a serem moderados no tamanho dos ficheiros para *upload*. Nas seis fichas de avaliação que se realizaram em MESTAT, verificou-se que o total de *uploads* de ficheiros efetuado por cada aluno segue uma distribuição normal com valor esperado de 1.75 MB e desvio padrão 0.45MB.

Além disso, sabe-se que em cada ficha de avaliação foram efetuados em média 20 *uploads*. Admita que o número de *uploads* segue uma distribuição de *Poisson*.

- a) Calcule a probabilidade de o número de *uploads* nos primeiros 15 minutos da ficha de avaliação ser superior ou igual a 4.

Solução: 0.9897

- b) Calcule o valor esperado e o desvio padrão de o número de fichas de avaliação com menos do que 25 *uploads*.

Solução: $\mu = 5.21$, $\sigma = 0.828$

- c) Calcule a probabilidade de o total de MBs em *uploads* submetido por um aluno de MESTAT ser inferior a 2.1MB.

Solução: 0.7816

- d) Sabendo que em cada ficha de avaliação participam 25 alunos, calcule a probabilidade de numa ficha de avaliação ser excedida a capacidade do servidor.

Solução: 0.9622 (nota: necessário ter em atenção que é uma população simétrica)

2. (8 VALORES) Um laboratório de análises clínicas começou, no início deste mês, a realizar testes de rastreio serológico numa universidade portuguesa para detetar o número de pessoas com imunidade a um determinado vírus. Até ao final da semana passada, o número de rastreios positivos (pessoas com imunidade ao vírus) encontrados num dia seguia a seguinte função de probabilidade:

Nº de rastreios positivos por dia	50	60	70	80	90	100
Probabilidade	0.10	0.15	0.25	0.25	0.20	0.05

- a) Esta semana já se efetuaram 500 testes de rastreio, tendo sido encontrados, em média, 75 rastreios positivos por dia. Com base neste resultado, teste ao nível de significância de 5% a hipótese de o valor esperado das pessoas com imunidade ao vírus ter aumentado na última semana

*Solução: $H_0: \mu = 74.5$ e $H_1: \mu > 74.5$;
 $\bar{X} = 75$, $VC = 1.645$; $ET = 0.823$; $pvalue \approx 20.5\% \rightarrow$ teste inconclusivo*

- b) Imagine que, de facto, o valor esperado do número rastreios positivos por dia aumentou para 75, mantendo a mesma variabilidade. Nesta situação, qual seria a probabilidade de, no teste anterior, não se concluir que houve um aumento no valor esperado do número de pessoas com imunidade ao vírus.

Solução: $\beta = 79.5\%$

- c) O departamento de controlo de qualidade do laboratório decidiu avaliar a técnica de rastreio que estava a ser utilizada. Recorrendo a uma técnica 100% fiável foram verificados os resultados de 200 testes efetuados esta semana, tendo-se verificado que 196 dos testes davam o resultado correto. Determine, com 95% de confiança, a proporção máxima de testes de rastreio com resultado incorreto.

Solução: $[-\infty, 0.0363]$ (nota: necessário comentar a violação de uma das condições da aproximação da Binomial pela Normal)

DEVE RESPONDER APENAS A UM DOS SEGUINTE PROBLEMAS

[pode optar por responder a todas as alíneas do problema 3 ou todas as alíneas do problema 4]

3. (4 VALORES) O projeto consistiu no desenvolvimento de um modelo de regressão para prever se um *post* numa rede social (neste caso, o *instagram*) vai ter comentários nas próximas 24h, com base no valor de várias variáveis, incluindo *page_total_likes* (número total de *likes* dos *posts* da conta, representado como um número inteiro), *category* (tipo de *post*; número inteiro), *weekday* (dia da semana; número inteiro), *hour* (hora do dia; número inteiro); *paid* (se o *post* foi pago ou não; binário).

- a) Foram testados 2 algoritmos, *Naive Bayes* e *Random Forest*, e as taxas de erro (i.e. proporção de previsões erradas) respetivas foram de 10% e 11%. Discuta se podemos dizer com certeza que o modelo obtido com *Naive Bayes* é melhor do que o modelo obtido com *Random Forest*? Que ferramenta estatística poderíamos usar para suportar a resposta à questão anterior?

Solução: (não divulgada)

- b) O projeto foi apresentado como um projeto de classificação. Mas poderia ser tratado como um problema de regressão:
- aplicando um algoritmo de regressão aos dados fornecidos.
 - mudando a medida de avaliação dos modelos para, por ex., o erro quadrático médio (*mean squared error*), no número de comentários nas próximas 24h.
 - mudando a variável-objetivo para ser o número de comentários nas próximas 24h, o problema passaria a ser prever esse valor.
 - aplicando aos dados fornecidos um algoritmo que possa ser usado tanto para classificação como para regressão.

Indique qual das opções anteriores é a mais correta.

Solução: *iii*

4. (4 VALORES) O *Preço Certo* é um popular concurso televisivo onde os concorrentes que o disputam passam por várias fases para tentarem ganhar o prémio principal, denominado “montra final”. A última fase de acesso à “montra final” consiste num pequeno jogo onde três concorrentes tentam obter a pontuação máxima (100 pontos) ou uma pontuação o mais alta possível que não ultrapasse 100 pontos. Neste jogo, cada concorrente pode rodar uma roda gigante, numerada de 5 a 100 em intervalos de 5 (ou seja, 20 possibilidades: 5, 10, 15, ..., 90, 95, 100), uma ou duas vezes. Caso um jogador opte por rodar duas vezes fica com a pontuação resultante da soma das duas jogadas. Avança para a “montra final” o concorrente com a pontuação mais alta que não exceda 100 pontos. Em caso de empate na pontuação mais alta cada um dos concorrentes empatados roda a roda gigante uma vez mais, avançando para a “montra final” o concorrente com a pontuação mais alta.

Notas: - um concorrente só começa a jogar após o anterior ter terminado de jogar;

- admita ser nula a probabilidade de serem necessárias duas ou mais rondas de desempate.

Numa determinada sessão o primeiro concorrente já jogou tendo excedido a pontuação máxima, enquanto o segundo concorrente obteve 95 pontos na primeira jogada e decidiu não jogar a segunda vez.

- a) Calcule a probabilidade de ocorrer um empate.

Solução: 0.095

- b) Calcule a probabilidade de o segundo concorrente passar à “montra final”.

Solução: 0.855